Actividad Práctica 1

Realizado por: Meneses Solorzano, Brandon Luis

1. Contexto

Ejercicio	Qué se entrega
1. Tabla Gold peliculas_rentables	Top 50 por retorno (taquilla ÷ presupuesto), con más de 10 000 votos en IMDB
2. Regla de calidad nueva	Rechazar películas sin género y sin director; medir el impacto en cuarentena
3. Gobierno de la tabla nueva	COMMENT, SET TAGS y GRANT de lectura

2. Ejercicio 1 — Tabla Gold peliculas_rentables

Razonamiento

- Retorno = recaudacion_mundial ÷ presupuesto, calculado con try_divide para que un divisor 0 devuelva NULL en vez de fallar.
- WHERE votos_imdb > 10000: filtro de fiabilidad. Sin él, películas con muy pocos votos dominarían el ranking. Un NULL en votos no cumple el filtro.
- recaudacion_mundial IS NOT NULL: en Silver el cero de taquilla se convirtió en NULL (nullif); esas películas no tienen retorno calculable.
- ORDER BY retorno DESC + LIMIT 50: se queda con las 50 mejores.
- coalesce(genero, 'Sin clasificar'): en Gold no se dejan NULL en las dimensiones (criterio de la sección 7 del notebook).

Consulta

```
CREATE OR REPLACE TABLE workspace.cine_gold.peliculas_rentables
COMMENT 'Top 50 películas por retorno (taquilla mundial / presupuesto). Solo películas con más de 10 000 votos en IMDB'
AS
SELECT
  titulo,
  fecha_estreno,
  coalesce(genero, 'Sin clasificar')                AS genero,
  estudio,
  presupuesto,
  recaudacion_mundial,
  round(try_divide(recaudacion_mundial, presupuesto), 2) AS retorno,
```

```
 votos_imdb,
 calificacion_imdb
FROM workspace.cine_silver.peliculas
WHERE votos_imdb > 10000
 AND recaudacion_mundial IS NOT NULL
ORDER BY retorno DESC
LIMIT 50
```

Resultado

#	Título	Presupuesto	Taquilla mundial	Retorno
1	Paranormal Activity	15,000	193,770,453	12,918.03
2	Mad Max	200,000	99,750,000	498.75
3	Super Size Me	65,000	29,529,368	454.3
4	The Blair Witch Project	600,000	248,300,000	413.83
5	El Mariachi	7,000	2,040,920	291.56
6	Night of the Living Dead	114,000	30,000,000	263.16
7	Halloween	325,000	70,000,000	215.38
8	The Texas Chainsaw Massacre	140,000	26,572,439	189.8
9	American Graffiti	777,000	140,000,000	180.18
10	Once	150,000	18,997,174	126.65
11	The Rocky Horror Picture Show	1,200,000	139,876,417	116.56
12	Napoleon Dynamite	400,000	46,140,956	115.35
13	Clerks	27,000	3,073,428	113.83
14	Friday the 13th	550,000	59,754,601	108.64
15	Open Water	500,000	52,100,882	104.2
16	Saw	1,200,000	103,096,345	85.91
17	Primer	7,000	565,846	80.84
18	The Evil Dead	375,000	29,400,000	78.4
19	ET: The Extra-Terrestrial	10,500,000	792,910,554	75.52
20	My Big Fat Greek Wedding	5,000,000	368,744,044	73.75
21	The Full Monty	3,500,000	257,938,649	73.7
22	Eraserhead	100,000	7,000,000	70
23	Pi	68,000	4,678,513	68.8
24	Crocodile Dundee	5,000,000	328,000,000	65.6
25	Chasing Amy	250,000	15,155,095	60.62
26	Dr. No	1,000,000	59,567,035	59.57
27	Four Weddings and a Funeral	4,500,000	242,895,809	53.98
28	Roger & Me	140,000	6,706,368	47.9
29	Blazing Saddles	2,600,000	119,500,000	45.96

30	Goldfinger	3,000,000	124,900,000	41.63
31	From Russia With Love	2,000,000	78,900,000	39.45
32	Jaws	12,000,000	470,700,000	39.23
33	The Godfather	7,000,000	268,500,000	38.36
34	La marche de l'empereur	3,400,000	129,437,223	38.07
35	Das Leben der Anderen	2,000,000	75,284,657	37.64
36	Fahrenheit 9/11	6,000,000	222,414,517	37.07
37	Dawn of the Dead	1,500,000	55,000,000	36.67
38	Grease	6,000,000	206,005,260	34.33
39	The Exorcist	12,000,000	402,500,000	33.54
40	Pretty Woman	14,000,000	463,400,000	33.1
41	Juno	7,000,000	230,327,671	32.9
42	Home Alone	15,000,000	476,684,675	31.78
43	Young Frankenstein	2,800,000	86,300,000	30.82
44	Saw II	5,000,000	152,925,093	30.59
45	The Sting	5,500,000	159,616,327	29.02
46	Flashdance	7,000,000	201,463,574	28.78
47	Porky's	4,000,000	109,492,484	27.37
48	Pulp Fiction	8,000,000	212,928,762	26.62
49	Lost in Translation	4,000,000	106,454,000	26.61
50	Slumdog Millionaire	14,000,000	365,257,315	26.09

Lectura: Paranormal Activity (retorno ≈ 12 918) es un valor atípico extremo: costó 15 000 USD y recaudó más de 193 millones. Después aparecen películas de muy bajo presupuesto (Mad Max, Super Size Me, The Blair Witch Project, El Mariachi). El ranking premia la eficiencia de la inversión, no la taquilla absoluta. El listado muestra solo las columnas de presupuesto, taquilla y retorno, las demás columnas se omitieron por simpleza en la documentación.

3. Ejercicio 2 — Regla de calidad «ni género ni director»

Cambio realizado

Se modificó la vista peliculas_evaluadas (sección 5.1) añadiendo un cuarto motivo de rechazo. La condición usa AND: solo se rechaza si faltan ambos datos a la vez; con OR se rechazarían muchas más filas, incluso con información útil.

```
CREATE OR REPLACE TEMP VIEW peliculas_evaluadas AS
SELECT *,
  array_compact(array(
    CASE WHEN titulo IS NULL                THEN 'titulo nulo' END,
    CASE WHEN fecha_estreno IS NULL         THEN 'fecha ilegible' END,
    CASE WHEN fecha_estreno > current_date()  THEN 'fecha futura' END,
    CASE WHEN presupuesto IS NULL
```

```
       OR presupuesto <= 0            THEN 'presupuesto no positivo' END,
  -- EJERCICIO 9.2: regla nueva
  CASE WHEN genero IS NULL
       AND director IS NULL           THEN 'sin genero ni director' END
 )) AS motivos_rechazo
FROM peliculas_tipadas
```

Después se volvió a ejecutar el flujo desde 5.1: cuarentena (5.2), Silver (5.3), reconciliación (5.4), contrato (6), Gold (7), documentación y etiquetas (8.x).

Consulta para medir el impacto

```
SELECT
  count(*) FILTER (WHERE array_contains(motivos_rechazo, 'sin genero ni director')
                   AND size(motivos_rechazo) = 1)            AS filas_adicionales,
  count(*) FILTER (WHERE array_contains(motivos_rechazo, 'sin genero ni director')
                   AND size(motivos_rechazo) > 1)            AS ya_estaban_en_cuarentena,
  count(*) FILTER (WHERE size(motivos_rechazo) > 0)          AS cuarentena_total,
  count(*) FILTER (WHERE size(motivos_rechazo) > 0
                  AND NOT array_contains(motivos_rechazo, 'sin genero ni director'))
                                     AS solo_otros_motivos
FROM peliculas_evaluadas
```

Resultado

Table +

	filas_adicionales	ya_estaban_en_cuarentena	cuarentena_total	solo_otros_motivos
1	162	5	180	13

Indicador	Antes	Después	Diferencia
Filas en cuarentena	18	180	+162
Filas en Silver	3 183	3 021	−162
Bronze = Silver + cuarentena	3 201	3 201	0

Respuesta: caen 162 filas más en cuarentena. 167 películas no tienen ni género ni director, pero 5 de ellas ya estaban rechazadas por otro motivo (p. ej. fecha futura), por eso el aumento neto es 162 y no 167. La reconciliación sigue cuadrando (180 + 3 021 = 3 201): no se perdió ninguna fila.

Efecto en cascada sobre Gold

Al cambiar Silver, las tablas Gold se recalculan. En peliculas_rentables salen House of Wax y The Last House on the Left, y entran Lost in Translation y Slumdog Millionaire. Una regla de calidad no es un detalle técnico: modifica los números que ve el negocio.

4. Ejercicio 3 — Documentar, etiquetar y conceder permiso

Documentación (como 8.1)

El COMMENT de la tabla se definió en el CREATE (Ejercicio 1). Los comentarios de columna:

```
COMENTARIOS_GOLD = {
    "titulo":             "Título original de la película",
    "fecha_estreno":      "Fecha de estreno en salas",
    "genero":             "Género principal. "Sin clasificar" si el origen no lo informó",
    "estudio":            "Estudio distribuidor",
    "presupuesto":        "Presupuesto de producción en dólares. Dato financiero confidencial",
    "recaudacion_mundial": "Taquilla mundial en dólares",
    "retorno":            "Retorno de la inversión: recaudación mundial dividida entre presupuesto, 2
decimales",
    "votos_imdb":         "Número de votos en IMDB. Siempre mayor que 10 000 en esta tabla",
    "calificacion_imdb":   "Nota media de IMDB, de 0 a 10",
}

for columna, texto in COMENTARIOS_GOLD.items():
    spark.sql(f"ALTER TABLE workspace.cine_gold.peliculas_rentables "
              f"ALTER COLUMN {columna} COMMENT '{texto}'")
    print("Documentada:", columna)
```

Resultado:

```
Documentada: titulo
Documentada: fecha_estreno
Documentada: genero
Documentada: estudio
Documentada: presupuesto
Documentada: recaudacion_mundial
Documentada: retorno
Documentada: votos_imdb
Documentada: calificacion_imdb
```

En el notebook se aplican las nueve columnas con un bucle, como en 8.1, y se verifica con DESCRIBE TABLE.

```
DESCRIBE TABLE workspace.cine_gold.peliculas_rentables
```

Resultado

Table +

	col_name	data_type	comment
1	titulo	string	Título original de la película
2	fecha_estreno	date	Fecha de estreno en salas
3	genero	string	Género principal. 'Sin clasificar' si el origen no lo informó
4	estudio	string	Estudio distribuidor
5	presupuesto	bigint	Presupuesto de producción en dólares. Dato financiero confidencial
6	recaudacion_mund...	bigint	Taquilla mundial en dólares
7	retorno	double	Retorno de la inversión: recaudación mundial dividida entre presupuesto, 2 decimales
8	votos_imdb	bigint	Número de votos en IMDB. Siempre mayor que 10 000 en esta tabla
9	calificacion_imdb	double	Nota media de IMDB, de 0 a 10

Etiquetas (como 8.2)

```
ETIQUETAS_GOLD = [
    "ALTER TABLE workspace.cine_gold.peliculas_rentables "
    "SET TAGS ('capa' = 'gold', 'dominio' = 'cine', 'certificada' = 'si')",

    "ALTER TABLE workspace.cine_gold.peliculas_rentables ALTER COLUMN presupuesto "
    "SET TAGS ('sensibilidad' = 'confidencial')",
]

for sentencia in ETIQUETAS_GOLD:
    spark.sql(sentencia)

print("Etiquetas aplicadas")
```

Se verifica consultando information_schema.table_tags y information_schema.column_tags. La columna presupuesto hereda la etiqueta de confidencial que ya tenía en Silver, para que la clasificación sea coherente entre capas.

```
SELECT 'tabla' AS nivel, table_name, '' AS column_name, tag_name, tag_value
FROM workspace.information_schema.table_tags
WHERE schema_name = 'cine_gold' AND table_name = 'peliculas_rentables'
UNION ALL
SELECT 'columna', table_name, column_name, tag_name, tag_value
FROM workspace.information_schema.column_tags
WHERE schema_name = 'cine_gold' AND table_name = 'peliculas_rentables'
```

Resultado

Table

	n.	table_name	column_name	tag_name	tag_value
1	tabla	peliculas_rentables		capa	gold
2	tabla	peliculas_rentables		dominio	cine
3	tabla	peliculas_rentables		certificada	si
4	columna	peliculas_rentables	presupuesto	sensibilidad	confidencial

Permiso de lectura (como 8.3)

```
GRANT SELECT ON TABLE workspace.cine_gold.peliculas_rentables TO `account users`
```

```
SHOW GRANTS ON TABLE workspace.cine_gold.peliculas_rentables
```

Resultado

Table

	Principal	ActionType	ObjectType	ObjectKey
1	account users	SELECT	TABLE	workspace.cine_gold.peliculas_rentables
2	account users	SELECT	SCHEMA	workspace.cine_gold

Con SHOW GRANTS debe aparecer el privilegio SELECT para account users. Se aplica el principio de mínimo privilegio: solo lectura (SELECT), sobre una tabla Gold, y no sobre Bronze o Silver. En una empresa real se concedería a un grupo concreto (p. ej. analistas_cine).

Observación de gobierno: la tabla incluye presupuesto, que está etiquetado como confidencial. Conceder SELECT sobre ella expone esa columna a todos los destinatarios. Si no debiera verse, las alternativas son una vista sin esa columna (como catalogo_publico, sección 7.1) o una máscara de columna.

5. Pregunta para pensar

Las 16 películas con fecha futura están en cuarentena. ¿Quién debería decidir si se corrigen a mano, se descartan o se cambia la regla?

No es una decisión técnica. Debería tomarla el dueño del dato (data owner) del dominio cine, es decir, quien responde por el negocio, apoyado por el responsable de calidad (data steward), que investiga cada caso. El equipo de ingeniería actúa como ejecutor: puede explicar qué pasó (un año de dos dígitos mal interpretado), pero no decide cuál es el valor correcto.

La decisión debe quedar registrada (quién, cuándo y por qué) y comunicarse a los consumidores de Gold, porque cada opción cambia sus cifras. Por eso el gobierno de datos no se reduce a permisos: incluye roles, responsabilidades y procesos de decisión.