Actividad Práctica 2 — PySpark

Sesión 2: Caso de negocio con samples.tpch

Realizado por: Meneses Solorzano, Brandon Luis

Preparación común

Tablas de samples.tpch utilizadas: orders, customer y nation.

```
from pyspark.sql import functions as F


orders   = spark.table("samples.tpch.orders")
customer = spark.table("samples.tpch.customer")
nation   = spark.table("samples.tpch.nation")
```

```
3 dataframes: customer, nation, orders
  customer: pyspark.sql.connect.dataframe.DataFrame
    c_custkey: long
    c_name: string
    c_address: string
    c_nationkey: long
    c_phone: string
    c_acctbal: decimal(18,2)
    c_mktsegment: string
    c_comment: string
  nation: pyspark.sql.connect.dataframe.DataFrame
    n_nationkey: long
    n_name: string
    n_regionkey: long
    n_comment: string
  orders: pyspark.sql.connect.dataframe.DataFrame
    o_orderkey: long
    o_custkey: long
    o_orderstatus: string
    o_totalprice: decimal(18,2)
    o_orderdate: date
    o_orderpriority: string
    o_clerk: string
    o_shippriority: integer
    o_comment: string
```

Ejercicio 1. Pedidos por estado

Enunciado

¿Cuántos pedidos hay en cada estado (o_orderstatus) y cuál es el monto total de cada uno?

Pista: groupBy sobre orders con dos agregaciones: count y sum de o_totalprice.

Código PySpark

```
resultado_1 = (orders
    .groupBy("o_orderstatus")
    .agg(F.count("*").alias("num_pedidos"),
         F.sum("o_totalprice").alias("monto_total"))
    .orderBy("o_orderstatus"))

display(resultado_1)
```

Resultado obtenido

	o_orderstatus	num_pedidos	monto_total
1	F	3654501	549181919365.27
2	O	3654310	548923692869.55
3	P	191189	35333603011.43

Ejercicio 2. Evolución anual

Enunciado

¿Cuántos pedidos y qué monto total hay por año (o_orderdate)? Ordena del año más antiguo al más reciente.

Pista: Crea la columna año con F.year(...) y agrupa por ella.

Código PySpark

```
resultado_2 = (orders
    .withColumn("año", F.year("o_orderdate"))
    .groupBy("año")
    .agg(F.count("*").alias("num_pedidos"),
         F.sum("o_totalprice").alias("monto_total"))
    .orderBy("año"))

display(resultado_2)
```

Resultado obtenido

Table +

	año	num_pedidos	monto_total
1	1992	1139873	172177707475.98
2	1993	1138893	172229906369.71
3	1994	1137944	172079589599.59
4	1995	1136308	171632673720.20
5	1996	1141556	172605588830.66
6	1997	1137325	171861381581.98
7	1998	668101	100852367668.13

Ejercicio 3. Pedidos grandes ya finalizados

Enunciado

¿Cuántos pedidos finalizados (o_orderstatus = 'F') tienen un monto (o_totalprice) mayor a 100,000?

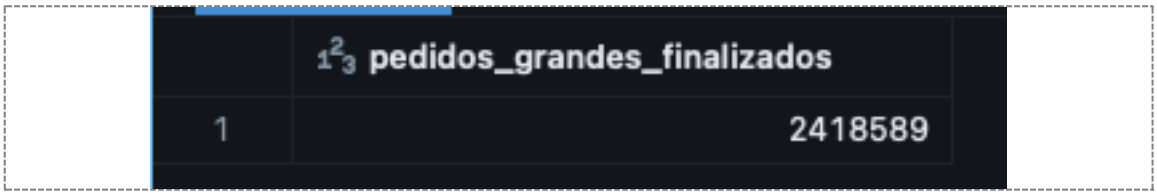
Pista: Usa filter con las dos condiciones unidas con & (cada una entre paréntesis) y luego agg(F.count("")).*

Código PySpark

```
resultado_3 = (orders
    .filter((F.col("o_orderstatus") == "F") & (F.col("o_totalprice") > 100000))
    .agg(F.count("*").alias("pedidos_grandes_finalizados")))


display(resultado_3)
```

Resultado obtenido



	pedidos_grandes_finalizados
1	2418589

Ejercicio 4. Clientes por segmento

Enunciado

¿Cuántos clientes hay en cada segmento de mercado (c_mktsegment)? Ordénalos de mayor a menor.

Pista: groupBy sobre customer y count.

Código PySpark

```
resultado_4 = (customer
    .groupBy("c_mktsegment")
    .agg(F.count("*").alias("num_clientes"))
    .orderBy(F.desc("num_clientes")))

display(resultado_4)
```

Resultado obtenido

Table +

	c_mktsegment	num_clientes
1	BUILDING	150297
2	FURNITURE	150190
3	MACHINERY	150165
4	HOUSEHOLD	149687
5	AUTOMOBILE	149661

Ejercicio 5. Clientes por país

Enunciado

¿En qué 5 países (n_name) hay más clientes? Muestra el país y el número de clientes, de mayor a menor.

Pista: Une customer con nation (c_nationkey = n_nationkey), agrupa por n_name y cuenta.

Código PySpark

```
resultado_5 = (customer
    .join(nation, customer.c_nationkey == nation.n_nationkey)
    .groupBy("n_name")
    .agg(F.count("*").alias("num_clientes"))
    .orderBy(F.desc("num_clientes"))
    .limit(5))

display(resultado_5)
```

Resultado obtenido

Table +

	n_name	num_clientes
1	INDONESIA	30401
2	IRAN	30257
3	INDIA	30234
4	IRAQ	30232
5	ETHIOPIA	30201

Ejercicio 6. Ticket promedio por segmento

Enunciado

¿Cuál es el ticket promedio (monto promedio por pedido, o_totalprice) de cada segmento de mercado? Ordénalo de mayor a menor.

Pista: Une orders con customer (o_custkey = c_custkey), agrupa por c_mktsegment y usa F.avg.

Código PySpark

```
resultado_6 = (orders
    .join(customer, orders.o_custkey == customer.c_custkey)
    .groupBy("c_mktsegment")
    .agg(F.round(F.avg("o_totalprice"), 2).alias("ticket_promedio"))
    .orderBy(F.desc("ticket_promedio")))

display(resultado_6)
```

Resultado obtenido

Table +

	c_mktsegment	ticket_promedio
1	FURNITURE	151162.89
2	BUILDING	151145.72
3	MACHINERY	151127.45
4	HOUSEHOLD	151112.32
5	AUTOMOBILE	151077.38